

BUSINESS DATA ANALYTICS APPLIED LAB #2: RISK MANAGEMENT & OSH ANALYTICS (CRISP-DM)

WEEK 4

Asignatura: Data Analytics (Código: 43390860)

Profesor: Ing. Elias Buitrago Bolivar MSc.

Semana: 4 – Metodologías de Ciclo de Vida y Preparación de Datos

1. CONTEXTO DE NEGOCIO (EL DESAFÍO)

Un conglomerado de 150 empresas está alarmado por el aumento en los reportes de accidentes laborales. El costo de las incapacidades y el impacto humano están afectando la productividad global. La gerencia no solo necesita saber cuántos accidentes ocurren, sino que requiere identificar patrones de riesgo para implementar una estrategia de prevención. Su misión como analista de datos consiste en aplicar la metodología CRISP-DM para consolidar fuentes de datos dispersas, generar evidencia visual sobre los factores de riesgo (jornada, capacitación y sector) y proponer reglas de negocio preventivas. Como punto de partida se le recomienda tener en cuenta lo siguiente:

- i. *Cruzar la información:* Vincular los accidentes con el perfil del trabajador y el sector de la empresa.
- ii. *Identificar factores de riesgo:* ¿Influye la jornada (diurna/nocturna)? ¿Sirve realmente la capacitación para prevenir accidentes?
- iii. *Evaluar la gestión:* ¿Las empresas con sistema de gestión tienen efectivamente menos accidentes?

2. OBJETIVOS DE APRENDIZAJE

- a) Aplicar las fases de la metodología CRISP-DM en un proyecto de analítica real.
- b) Realizar procesos de Data Preparation avanzados mediante la unión de múltiples fuentes (Triple Join).
- c) Generar visualizaciones descriptivas para identificar variables con mayor correlación al riesgo laboral.

3. DESCRIPCIÓN DE LOS DATASETS

Para este laboratorio contará con los siguientes archivos en formato CSV:

- 1) *trabajadores.csv*: Perfil demográfico, cargo, jornada y antigüedad del personal.
- 2) *empresas.csv*: Información del sector económico y estado del sistema de gestión.
- 3) *accidentes.csv*: Registro histórico de incidentes laborales vinculados por ID.

4. CÓDIGO (PYTHON)

Siga estos pasos en su entorno de Google Colab o Jupyter Notebook, para consolidar la Tabla Maestra de Riesgos y generar la evidencia del análisis. El código proporcionado brinda una base, pero no le responde todas las preguntas. Por lo tanto, debe generar otros gráficos que considere necesarios para profundizar en su análisis.

```
# Importar librerías
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# Paso 1: Carga y Preparación de Datos (Data Understanding)
df_trabajadores = pd.read_csv('trabajadores.csv')
df_empresas = pd.read_csv('empresas.csv')
df_accidentes = pd.read_csv('accidentes.csv')

# Paso 2: Consolidación de Información (Data Preparation / Triple Join)
# Unimos trabajadores con empresas
df_merge = pd.merge(df_trabajadores, df_empresas, left_on='empresa',
                    right_on='id_empresa')

# Unir con accidentes (Left join para no perder a quienes NO tuvieron accidentes)
df_final = pd.merge(df_merge, df_accidentes, on='id_trabajador', how='left')

# Crear variable binaria: 1 si hubo accidente, 0 si no
df_final['incidente'] = df_final['id_accidente'].notnull().astype(int)

# Cruzar el resultado anterior con la base de clientes
full_report = sales_with_prices.merge(customers, left_on='Customer ID',
                                     right_on='ID', how='left')

# Paso 3: Modelado Descriptivo (Visualización de Evidencia)
plt.figure(figsize=(15, 5))

# Gráfico 1: Riesgo por Jornada
plt.subplot(1, 3, 1)
sns.barplot(data=df_final, x='jornada', y='incidente', estimator=lambda x:
            sum(x)/len(x)*100)
plt.title('% Tasa de Accidentes por Jornada')

# Gráfico 2: Impacto de la Capacitación
plt.subplot(1, 3, 2)
```

```

sns.barplot(data=df_final, x='capacitado', y='incidente', estimator=lambda x:
sum(x)/len(x)*100)
plt.xticks([0, 1], ['No', 'Sí'])
plt.title('¿La capacitación reduce el riesgo?')

# Gráfico 3: Sectores más críticos (Top 5)
plt.subplot(1, 3, 3)
df_final.groupby('sector_economico')['incidente'].mean().sort_values(ascending=False).head(5).plot(kind='bar', color='salmon')
plt.title('Top 5 Sectores en Riesgo')

plt.tight_layout()
plt.show()

# --- SECCIÓN DE EXPLORACIÓN AUTÓNOMA ---
# INSTRUCCIÓN: El estudiante debe generar otros gráficos que
# considere necesarios para profundizar en su análisis.
# Sugerencia: Explore la relación entre 'antigüedad', 'nivel_educativo' o
# 'sistema_gestion' respecto a la variable 'incidente'.

```

5. EL ENTREGABLE: ONE-PAGE EXECUTIVE REPORT

Con base en la salida de su código, usted debe entregar un informe de una sola página en formato PDF (*one-page executive report*). Imagine que este documento llegará a la mesa del director ejecutivo. Por lo tanto, no debe incluir código, sino análisis, estadísticas, gráficos y recomendaciones para la toma de decisiones.

Estructura del One-Page Report (Plantilla a seguir):

TITULO: ESTRATEGIA DE PREVENCIÓN DE RIESGOS - MARCO CRISP-DM

1. Mapeo metodológico: Describa brevemente qué actividad técnica realizó en las fases de *Data Understanding* y *Data Preparation* basándose en el código ejecutado.
2. Diagnóstico de factores de riesgo: Según los gráficos, ¿cuál es la jornada más peligrosa? ¿Qué impacto real tiene la capacitación en la reducción de incidentes? (Cite cifras).
3. Hallazgos adicionales: Describa qué descubrió en las gráficas que generó de forma autónoma (ej: relación de la antigüedad o el sistema de gestión con el riesgo).
4. Recomendación ERP (Insight Accionable): Proponga una regla de negocio automática para el sistema que ayude a prevenir futuros accidentes (ej: alertas de capacitación obligatoria para sectores o cargos específicos).

6. CRITERIOS DE EVALUACIÓN

<i>Criterio</i>	<i>Descripción</i>	<i>Peso</i>
<i>Rigor Metodológico</i>	Describe correctamente el flujo del proyecto dentro de las fases de CRISP-DM.	40%
<i>Análisis de Evidencia</i>	Capacidad de convertir las gráficas (base y propias) en conclusiones de negocio.	30%
<i>Síntesis y Comunicación</i>	El informe es ejecutivo, directo y cumple con el formato de una sola página.	20%
<i>Ejecución Técnica</i>	El código realiza el triple join y genera visualizaciones adicionales pertinentes.	10%